

KHOA HỌC MÁY TÍNH | MÃ NGÀNH: 8480101

Thuyết minh giải pháp ứng dụng các kỹ thuật AI hỗ trợ giải đáp thắc mắc cho người dùng trong website thương mại

Người trình bày: Nguyễn Trung Tín

Email: nguyentrungtin1002@gmail.com

Số điện thoại: 0826780002

PHẦN 1: TỔNG QUAN HỆ THỐNG

Phân tích nhu cầu thực tế và kiến trúc giải pháp

Vấn đề & Nhu cầu thực tế

Thực trạng hiện nay

- Khối lượng các thắc mắc của khách hàng ngày càng lớn khiến nhân lực chăm sóc khách hàng khó phản hồi nhanh chóng và đồng nhất.
- Thông tin phân tán ở nhiều nguồn, dẫn đến việc tốn thời gian tra cứu, dễ bỏ sót thông tin.
- Một số Chatbot truyền thống còn nhiều hạn chế, gặp khó khăn với các ngữ cảnh phức tạp, thiếu sự linh hoạt trong tư vấn bán hàng.
- Các mô hình AI ngôn ngữ lớn (LLM) như GPT tuy có thể đáp ứng về hội thoại tự nhiên, nhưng gặp vấn đề về thông tin nội bộ.

Nhu cầu cấp thiết

- Nhu cầu tự động hóa hỗ trợ tư vấn khách hàng 24/7, giúp giảm tải cho nhân viên CSKH, trả lời nhanh các hội thoại phổ biến.
- Hệ thống đảm bảo độ chính xác của các câu trả lời, dựa trên thông tin nội bộ chính thức thay vì chỉ dựa trên mô hình ngôn ngữ lớn có sẵn.
- Hệ thống có thể hỗ trợ đa ngôn ngữ với người dùng mà vẫn đảm bảo trả lời chính xác, hợp ngữ cảnh.
- Khả năng mở rộng và cập nhật thông tin nhanh chóng, không phải huấn luyện từ đầu.

Định hướng giải pháp

Hệ thống Chatbot ứng dụng Retrieval-Augmented Generation (RAG) với mô hình ngôn ngữ lớn (LLM)

- Xây dựng hệ thống hỏi đáp tự động dựa trên Retrieval-Augmented Generation kết hợp ngôn mô hình ngôn ngữ lớn GPT.
- Sử dụng cơ sở tri thức nội bộ để cung cấp thông tin chính xác và cập nhật cho người dùng.
- Kết hợp dữ liệu truy xuất với khả năng suy luận của LLM để tạo câu trả lời tự động, dễ hiểu.
- Hỗ trợ đa ngôn ngữ và khả năng mở rộng trong tương lai.

Kiến trúc tổng quát hệ thống



Sơ đồ ngữ cảnh của hệ thống




Sơ đồ kiến trúc của hệ thống




Sơ đồ kiến trúc của kỹ thuật
AI cho ứng dụng

Kiến trúc tổng quát hệ thống



Sơ đồ ngữ cảnh của hệ thống website thương mại


Kiến trúc tổng quát hệ thống




Sơ đồ kiến trúc của hệ thống website thương mại

Kiến trúc tổng quát hệ thống

1. Document Processing Routine




2. Question Answering Routine



Sơ đồ kiến trúc ứng dụng kỹ thuật AI

Mô hình hóa với sơ đồ UML



- ✓ Use case Diagram: Mô tả vai trò sử dụng hệ thống.
- ✓ Sequence Diagram: Luồng tương tác thời gian thực.
- ✓ Activity Diagram: Mô tả quy trình hoạt động.



Mô hình hóa với sơ đồ UML


✔ Use Case Diagram: Mô tả vai trò sử dụng hệ thống.

✔ Sequence Diagram: Mô tả luồng tương tác



Mô hình hóa với sơ đồ UML

✓ Activity Digram cho quy trình RAG




PHẦN 2: CHỦ ĐỀ CHUYÊN SÂU


Ứng dụng kỹ thuật RAG để nâng cao chất lượng phản hồi của Chatbot cho hệ thống tự động phản hồi thắc mắc người dùng

Kỹ thuật RAG là gì?

RAG (Retrieval-Augmented Generation) là một kỹ thuật AI giúp cải thiện đầu ra của các mô hình ngôn ngữ lớn bằng cách truy xuất thông tin bên ngoài có liên quan như những tài liệu, cơ sở dữ liệu hay báo cáo trong những lĩnh vực chuyên biệt và đưa nó vào ngữ cảnh của mô hình trước khi tạo ra phản hồi. Kỹ thuật này giúp giảm thiểu các sai lệch, cung cấp các dữ kiện cập nhật và cho phép đưa ra các câu trả lời chuyên sâu và cụ thể bằng cách kết hợp hệ thống truy xuất với các mô hình ngôn ngữ lớn.



Các khối xử lý của kỹ thuật RAG




Các khối xử lý chính của kỹ thuật RAG

1. Khối xử lý dữ liệu cơ sở
2. Khối phân đoạn dữ liệu (Chunking)
3. Khối mã hóa số dữ liệu (Embedding)
4. Khối lưu trữ dữ liệu được mã hóa số (Vector Database)
5. Khối đặt câu lệnh cho AI (prompting)
6. Khối kết nối tới mô hình ngôn ngữ lớn (LLM)

1. Khối xử lý dữ liệu cơ sở (lý thuyết)

Trong thực tế, các loại dữ liệu có thể ở nhiều định dạng khác nhau, do đó việc xác định các kiểu dữ liệu muốn tham gia trong hệ thống hỏi đáp là bước tiên quyết và nó sẽ ảnh hưởng đến các bước tiếp theo và đến kết quả cuối cùng của hệ thống

Phân loại các thể loại dữ liệu và đặc trưng



1. Khối xử lý dữ liệu cơ sở (ứng dụng)

Các dạng dữ liệu trong dự án và ảnh hưởng đến quá trình phân đoạn (Chunking)

Tên tài liệu	Kiểu dữ liệu	Đặc trưng trong RAG	Xử lý trước phân đoạn
1.Candle_benefit.docx 2.Some_Fragrance_layers_of_scented_candles.docx 3.Chinh_sach_mua_hang.docx 4.Safe_Usage_guidance.docx	Word (.docx)	Các file word này trong dự án được tổ chức theo cấu trúc markdown với các tiêu đề cụ thể, nội dung bao gồm các đoạn text đơn thuần	Ưu tiên phân đoạn theo tiêu đề để đảm bảo về ngữ nghĩa, tiếp đến theo số lượng token giới hạn được cấu hình sẵn
1.FAQ_Candle_knowledge.json 2.FAQ_Discount_program.json 3.FAQ_Policies.json 4.FAQ_Candle_product.json 5.FAQ_Accesories_product.json 6.FAQ_Lumos_product.json 7.FAQ_Product_Catalog.json 8.FAQ_User_guidance.json	JSON (.json)	Dạng thuộc tính, từng đoạn ghi chia theo dạng câu hỏi - trả lời rõ ràng	Chia theo mỗi cặp hỏi - đáp là 1 đoạn rõ ràng.
coupons.csv	CSV (.csv)	Dữ liệu có cấu trúc dạng bảng với các trường cụ thể	Mỗi bản ghi là một đoạn và không cần phân đoạn thêm
3_Day_WKND.md (Tương tự file cho các sản phẩm khác)	Markdown (.md)	Từng sản phẩm sẽ có 1 file riêng chứa thông tin riêng biệt, mô tả rõ ràng và linh động	Mỗi file markdown cho sản phẩm là 1 đoạn và không cần phân đoạn thêm

Lưu ý: Đính kèm các thông tin metadata để lưu về nguồn tài liệu và thể loại thông tin, giúp cải tiến về sau như re-ranking, hybrid search

1. Khối xử lý dữ liệu cơ sở (kết quả)

AMAZING USES OF SCENTED CANDLES

Decorating Your Living Space

- Nowadays, scented candles are designed in many unique and eye-catching shapes and packaging to serve the purpose of decorating your living space.
- Besides furniture and decor accessories, fragrance can also "decorate" your living space, expressing your personal style. Depending on the choice of scented candles, guests visiting your home will gain a better understanding of the homeowner's style, personality, or emotions.

Relax your mind, relieve stress

- According to Dr. Pamela Dalton, a researcher from the [Monell](#) Center for the study of the interaction between human senses and chemicals in Philadelphia: "The part of the brain that receives and processes scents is actually very close to the parts of the brain that handle human memory and emotions."

File: Lợi ích của nến (Candle_Benefit.docx)

A	B	C	D	E
coupon_id	code	discount_type	discount_value	min_order_value
1	NEWYEAR2025	percent	15	200000
2	FREESHIP50	amount	50000	100000
3	WELCOME10	percent	10	0
4	VIPMEMBER	amount	100000	500000
5	SUMMERSALE	percent	20	300000

File: Chương trình khuyến mãi (coupons.csv)

```
{
  "question": "What are top notes in a scented candle?",
  "answer": "Top notes are the first scents perceived when a candle is lit, crea
},
{
  "question": "How long do top notes typically last?",
  "answer": "Top notes usually last about 10 minutes after the candle is lit bef
},
{
  "question": "What are some common examples of top notes?",
  "answer": "Common top notes include citrus scents such as lemon and orange, fl
},
{
  "question": "What are middle notes in a scented candle?",
  "answer": "Middle notes, also called heart notes, form the core character of a
```

File: Những câu hỏi phổ biến về kiến thức nến (FAQ_Candle_knowledge.json)

```
Product name: 3 Day WKND
Category: Scented Candle
Main Scents:
- Green Apple
- Cucumber
- Waterlily
Season:
- Spring
- Summer
- Any Season
Fragrance Family: Fruity
Scent Profile: Top notes is green apple, cucumber, next is middle notes such as Lily of the valley,
```

File: Thông tin chi tiết sản phẩm (3_Day_WKND.md)

2. Khối phân đoạn dữ liệu - Chunking (lý thuyết)


Phân đoạn dữ liệu (Chunking) là quá trình chia tài liệu gốc thành nhiều đoạn văn bản nhỏ (chunks) trước khi thực hiện quá trình mã hóa số (embedding) và lưu trữ vào Cơ sở dữ liệu (Vector Database). Mỗi Chunks là đơn vị nhỏ nhất mà hệ thống Truy xuất (Retrieval) có thể tìm kiếm và trả về cho mô hình ngôn ngữ lớn (LLM). Chính vì thế chất lượng quá trình phân đoạn sẽ ảnh hưởng trực tiếp đến hiệu quả truy xuất thông tin và độ chính xác của câu trả lời

Các phương thức phân đoạn phổ biến

Phương pháp	Ứng dụng	Ưu điểm	Nhược điểm
Phân đoạn với độ dài cố định	Khi muốn chia theo cụ thể số lượng token tối đa (ví dụ: mỗi chunks 1000 tokens)	Nhanh chóng và dễ triển khai	Có thể bị cắt giữa câu, làm mất ngữ nghĩa của câu.
Phân đoạn đệ quy	Khi file có nhiều nội dung và có cấu trúc về mặt ngữ nghĩa. Phương pháp này sẽ ưu tiên cắt nhỏ theo thứ tự theo đề mục, theo đoạn văn, theo câu và theo từ,	Giữ ngữ nghĩa câu, ít cắt ngang câu	Vẫn có thể bị cắt mất ngữ nghĩa, không nhận biết được cấu trúc dữ liệu
Phân đoạn theo ngữ nghĩa	Khi file là các đoạn văn bản dài, ngữ nghĩa phức tạp. Phương pháp này sẽ chia đoạn dựa trên sự thay đổi về ngữ nghĩa	Đảm bảo giữ ngữ nghĩa tốt nhất, phù hợp với tài liệu dài, cải thiện truy xuất	Chi phí tính toán cao, tốn thời gian cho phân tích ngữ nghĩa, kích thước chunk không đều
Phân đoạn theo cấu trúc	Khi file tổ chức theo dạng markdown hay chủ động chia theo đề mục	Giữ nguyên ngữ nghĩa	Tốn nhiều thời gian ở bước chuẩn bị dữ liệu đầu vào
Phân đoạn theo thể loại tài liệu	Khi file đã được tổ chức có cấu trúc sẵn như các bảng hay mảng có sẵn và đủ nhỏ thì không cần phân đoạn thêm	Các nội dung giữ được sự toàn diện dữ liệu	Tốn nhiều thời gian ở bước chuẩn bị dữ liệu đầu vào

2. Khối phân đoạn dữ liệu - Chunking (ứng dụng)

Mô hình hóa quá trình phân đoạn của dự án



Kiểu dữ liệu	Phương thức phân đoạn
Word (.docx)	Phân đoạn đệ quy
JSON (.json)	Phân đoạn theo thể loại tài liệu
CSV (.csv)	Phân đoạn theo thể loại tài liệu
Markdown (.md)	Phân đoạn theo cấu trúc

Chọn phương pháp phân đoạn theo dạng tài liệu cho dự án

Kết quả quá trình phân đoạn dựa trên dạng tài liệu

	chunk_id	source	category	length	content
Word File	3	Candle_benefit.docx	Candle_Knowledge	491	# AMAZING USES OF SCENTED CANDLES## Decorating Your Living SpaceNowadays, scented candle
	4	Candle_benefit.docx	Candle_Knowledge	622	## Relax your mind, relieve stressAccording to Dr. Pamela Dalton, a researcher from the Monell Ce
CSV File	19	coupons.csv	Discount_Program	266	Coupon Code: NEWYEAR2025 Discount Type: percent Discount Value: 15.0
	20	coupons.csv	Discount_Program	263	Coupon Code: FREESHIP50 Discount Type: amount Discount Value: 50000.0
	21	coupons.csv	Discount_Program	257	Coupon Code: WELCOME10 Discount Type: percent Discount Value: 10.0
	22	coupons.csv	Discount_Program	263	Coupon Code: VIPMEMBER Discount Type: amount Discount Value: 100000.0
	23	coupons.csv	Discount_Program	266	Coupon Code: SUMMERSALE Discount Type: percent Discount Value: 20.0
Markdown File	25	3_Day_WKND.md	Product_Catalog	1984	Product name: 3 Day WKNDCategory: Scented CandleMain Scents: - Green Apple - Cucumber - Wat
JSON File	60	FAQ_Candle_knowledge.json	Candle_Knowledge	231	Question: What are top notes in a scented candle? Answer: Top not
	61	FAQ_Candle_knowledge.json	Candle_Knowledge	200	Question: How long do top notes typically last? Answer: Top notes
	62	FAQ_Candle_knowledge.json	Candle_Knowledge	250	Question: What are some common examples of top notes? Answer:
	63	FAQ_Candle_knowledge.json	Candle_Knowledge	246	Question: What are middle notes in a scented candle? Answer: Mid

3. Khối mã hóa số dữ liệu - Embedding (lý thuyết)

Mã hóa số dữ liệu (Embedding) là quá trình chuyển đổi dữ liệu đã phân đoạn (Chunking) thành các vector số có chiều cố định, sao cho ý nghĩa của dữ liệu được bảo toàn trong không gian vector, các vector này giúp máy tính đo được độ tương đồng về ngữ nghĩa (semantic similarity) giữa các đoạn văn. Chất lượng quá trình này sẽ ảnh hưởng trực tiếp đến khả năng truy xuất và độ chính xác, quyết định ngữ cảnh để cũng cung cấp cho mô hình ngôn ngữ lớn

Các mô hình Embedding phổ biến

Mô hình	Ứng dụng
BAAI/bge-large-en-v1.5	Độ chính xác cao cho tiếng Anh, phổ biến trong các hệ thống RAG
BAAI/bge-base-en-v1.5	Nhẹ hơn, tốc độ nhanh hơn, phù hợp triển khai thực tế
intfloat/e5-large-v2	Tối ưu cho semantic search và retrieval
sentence-transformers/all-MiniLM-L6-v2	Nhẹ, tốc độ cao, phù hợp thử nghiệm
OpenAI text-embedding-3-small	Chất lượng tốt, chi phí thấp khi sử dụng API
OpenAI text-embedding-3-large	Hiệu năng rất cao nhưng chi phí lớn hơn

→ Sử dụng mô hình “OpenAI text-embedding-3-small” cho dự án vì nhu cầu vừa phải và đồng bộ dịch vụ với mô hình ngôn ngữ lớn của OpenAI

4. Khối lưu trữ dữ liệu mã hóa số - Vector Database (lý thuyết)

Khối lưu trữ dữ liệu mã hóa số (Vector Database) là hệ thống chuyên dụng để lưu trữ, quản lý và truy xuất các vector đã được mã hóa (embedding) của dữ liệu. Thông qua các cấu trúc chỉ mục tối ưu và thuật toán tìm kiếm lân cận gần đúng (Approximate Nearest Neighbor - ANN), Vector Database cho phép thực hiện tìm kiếm ngữ nghĩa (Semantic Search) với độ trễ thấp trên tập dữ liệu có kích thước lớn. Trong hệ thống RAG, Vector Database đóng vai trò là kho tri thức, lưu trữ các mã hóa của các đoạn tài liệu (chunks) cùng với metadata và nội dung gốc để phục vụ quá trình truy xuất thông tin liên quan trước khi cung cấp ngữ cảnh cho mô hình ngôn ngữ lớn (LLM)


Các Vector Database phổ biến

Công nghệ	Loại	Đặc điểm
FAISS	Vector Index	Nhanh, chạy cục bộ, phù hợp với mô hình nhỏ
ChromaDB	Vector Database	Nhẹ, dễ tích hợp với LangChain/LlamaIndex
Milvus	Distributed Vector DB	Quy mô lớn, hỗ trợ hàng triệu đến hàng tỷ vector
Qdrant	Vector Database	Hỗ trợ metadata filtering rất mạnh
Pinecone	Cloud Vector DB	Dịch vụ quản lý hoàn toàn trên cloud
Weaviate	Vector Database	Hỗ trợ GraphQL và tìm kiếm kết hợp (Hybrid Search)

→ Trong dự án hệ thống sử dụng FAISS làm Vector Store để lưu trữ và lập chỉ mục (indexing) các vector embedding của tài liệu. Mặc dù FAISS về bản chất là một thư viện xây dựng chỉ mục vector, khi kết hợp với bộ lưu file nội bộ, nó đảm nhiệm vai trò của một Vector Database trong hệ thống RAG, cho phép lưu trữ Embedding, ánh xạ tới tài liệu gốc và thực hiện truy xuất ngữ nghĩa (Semantic Retrieval) hiệu quả.


4. Khối lưu trữ dữ liệu mã hóa số - Vector Database (ứng dụng)

Quá trình xử lý dữ liệu và lưu vào Vector Database



Trong quá trình lưu dữ liệu, FAISS sẽ giúp lưu trữ các vector đã mã hóa kèm cấu trúc chỉ mục (file index.faiss), ngoài ra còn lưu thông tin các tài liệu, metadata và cầu nối giữa các vector và tài liệu (file index.pkl)

Quá trình xử lý dữ liệu và lưu vào Vector Database



Trong quá trình hỏi đáp trực tiếp, sau khi có vector mã hóa của câu hỏi, FAISS sẽ tính toán các vector gần nhau để đưa ra những Vector có độ tương đồng cao nhất để làm ngữ cảnh cho câu hỏi và gửi đến LLM

Ghi chú: Consine Similarity là tính toán đo góc giữa hai vector. Góc càng nhỏ thì độ tương đồng ngữ nghĩa càng cao

4. Tính toán độ tương đồng (cơ sở lý thuyết)

Mục tiêu tính toán độ tương đồng về ngữ nghĩa giữa các vector sau khi mã hóa của câu hỏi và tài liệu có sẵn. Trong phạm vi của khai phá dữ liệu, có một số phương pháp tính toán được đề xuất như công thức Euclidean Distance, Cosine similarity hay Correlation, tùy vào nhu cầu sẽ lựa chọn phù hợp

Tiêu chí	Euclidean Distance	Cosine similarity	Correlation
Công thức	$d(A,B) = \sqrt{\sum_{i=1}^n (A_i - B_i)^2}$ Trong đó: - A : vector emdedding câu hỏi - B : vector embedding tài liệu - i : số chiều của vector Giá trị: - Càng gần 0 thì càng trùng khớp	$Cosine\ Similarity(A,B) = \frac{A \cdot B}{\ A\ \ B\ }$ Trong đó: - A : vector emdedding câu hỏi - B : vector embedding tài liệu $A \cdot B$: tích vô hướng , $\ A\$, $\ B\$ là độ dài vector Giá trị: 1 : cùng hướng (tương đồng cao nhất) 0 : không liên quan -1 : ngược hướng	$r = \frac{\sum_{i=1}^n (A_i - \bar{A})(B_i - \bar{B})}{\sqrt{\sum_{i=1}^n (A_i - \bar{A})^2} \sqrt{\sum_{i=1}^n (B_i - \bar{B})^2}}$ Trong đó: $\bar{A}$: giá trị trung bình vector embedding câu hỏi $\bar{B}$: giá trị trung bình vector embedding tài liệu Giá trị: 1 : tương quan hoàn hảo 0 : không có tương quan tuyến tính -1 : tương quan âm hoàn hảo
Ý nghĩa	Đo khoảng cách hình học giữa các vector trong không gian đặc trưng	Đo mức độ tương đồng thông qua góc giữa các vector	Đo mức độ tương quan tuyến tính giữa 2 vector
Ứng dụng	Phù hợp với dữ liệu mà độ lớn của vector mang nhiều ý nghĩa	Phù hợp với ứng dụng tìm kiếm ngữ nghĩa, góc vector quan trọng hơn độ lớn	Phù hợp với ứng dụng tính độ tương quan tuyến tính giữa các tập dữ liệu khác nhau
Phù hợp với RAG	x	✓	x

Thông qua đó, Cosine Similarity là công thức phù hợp nhất với ứng dụng RAG vì tập trung so sánh tương đồng ngữ nghĩa mà không quan tâm độ dài hay thể thức khác nhau của các câu hỏi

5. Khởi đặt câu lệnh cho LLM - Prompting (lý thuyết)

Prompting là quá trình xây dựng lời nhắc (prompt) để hướng dẫn cho mô hình ngôn ngữ lớn (LLM) thực hiện tác vụ mong muốn. Trong hệ thống RAG, prompt không chỉ chứa câu hỏi của người dùng mà còn bao gồm các đoạn ngữ cảnh (Retrieved Context) được truy xuất từ Vector Database nhằm giới hạn phạm vi trả lời dựa trên những kiến thức cơ sở có sẵn, bên cạnh đó có thể định hướng phong cách, định dạng câu trả lời tùy theo mục đích ứng dụng.

Các kỹ thuật Prompting phổ biến

Kỹ thuật	Mô tả	Ứng dụng
Zero-shot Prompting	Chỉ đưa hướng dẫn, không có ví dụ	Phổ biến trong RAG
One-shot Prompting	Cung cấp một ví dụ	Khi cần định dạng ổn định
Few-shot Prompting	Cung cấp nhiều ví dụ	Phân loại, trích xuất thông tin
Role Prompting	Gán vai trò cho mô hình	Chatbot, trợ lý AI
Chain-of-Thought (CoT)	Khuyến khích mô hình suy luận từng bước	Bài toán logic, toán học
Retrieval-Augmented Prompting	Chèn ngữ cảnh được truy xuất vào prompt	Kiến trúc RAG

→ Kỹ thuật prompting được ứng dụng trong dự án là **Retrieval-Augmented**

Các nguyên tắc thiết kế prompt

1. Quy định vai trò của AI
2. Xác định ngữ cảnh của nhiệm vụ
3. Xác định rõ nhiệm vụ cần thực hiện
4. Xác định định dạng kết quả
5. Tuân theo thứ tự: hướng dẫn → ngữ cảnh → câu hỏi

Ví dụ biểu mẫu cho Prompt

```
You are an AI assistant for an e-commerce system.

Use ONLY the provided context to answer.

If the answer cannot be found in the context,
respond that the information is unavailable.

Context:
{context}

Question:
{question}
```

5. Khởi đặt câu lệnh cho LLM - Prompting (ứng dụng)

Biểu mẫu prompting trong dự án

- Vai trò là trợ lý tư vấn bán nền, tính cách vui vẻ thân thiện
- Chỉ sử dụng thông tin từ tài liệu truy xuất
- Trả lời cùng ngôn ngữ với ngôn ngữ được hỏi
- Không sử dụng tài liệu bên ngoài, không đoán, không giả thuyết hay tìm kiếm website
- Nếu thông tin không rõ thì nói “Không tìm thấy dựa trên tài liệu được cung cấp”
- Các hướng dẫn mẫu khi trả lời về thông tin sản phẩm
- Các hướng dẫn mẫu khi trả lời về tư vấn sản phẩm phù hợp
- Lịch sử hội thoại (tùy chọn)
- Ngữ cảnh của câu hỏi
- Câu hỏi

Triển khai trong biểu mẫu

<pre>template = ("You are a helpful, friendly, and natural assistant for a private knowledge base.\n" "\n" "RULES:\n" "1) Use ONLY the provided context to answer.\n" "\n" "2) Answer in {language} language.\n" "\n" "3) Do NOT use outside knowledge, guessing, assumptions, or web information.\n" "\n" "4) If the answer cannot be clearly found in the provided context, reply ONLY with:\n" "\n" " \"I don't know based on the provided documents, you should contact admin for detail information.\"\n" "\n" " \"Do not add extra explanations.\"\n" "\n" "5) Never say phrases such as:\n" "\n" " \"According to the provided documents\"\n" "\n" " \"Based on the context\"\n" "\n" " \"The documents indicate\"\n" "\n" " \"or similar machine-like wording.\"\n" "\n" "6) Generate natural and human-friendly answers.\n" "\n" </pre>	<pre>"7) When the user asks for product recommendations:\n" " - Recommend the most relevant products from the context.\n" " - Explain briefly why each product matches the user's request.\n" " - Focus on fragrance, mood, atmosphere, occasion, and benefits.\n" " - Help the user make a decision.\n" " - Do NOT simply copy document content.\n" "\n" "8) Product documents may contain fields such as:\n" " Product Name\n" " Brand\n" " Price\n" " Color\n" " Weight\n" " Material\n" " Fragrance Family\n" " Top Notes\n" " Middle Notes\n" " Base Notes\n" " Keywords\n" "\n" " Only show fields that are relevant to the user's question.\n" " Do NOT dump all product attributes automatically.\n" "\n" "9) If the user asks specifically about:\n" " - Price\n" " - Weight\n" " - Material\n" " - Specifications\n" </pre>	<pre>" Then provide those details from the context.\n" "\n" "10) Do NOT mix languages in the final answer unless the user explicitly requests it.\n" "\n" "11) Do NOT show image paths, file paths, internal IDs, vector IDs, source file names, or creation dates.\n" "\n" "RESPONSE STYLE:\n" "- Use Markdown.\n" "- Use headings when listing multiple products.\n" "- Use bullet points when presenting attributes.\n" "- Do NOT use tables.\n" "- Use line breaks generously for readability.\n" "- Keep answers concise but helpful.\n" "- Never output large blocks of raw catalog data.\n" "- Highlight prices, discount percentages, coupon codes, and important dates using bold formatting.\n" "\n" "Chat History:\n" "{chat_history}\n" "\n" "Context:\n" "{context}\n" "\n" "Question:\n" "{question}")</pre>
---	---	--

6. Khối mô hình ngôn ngữ lớn - LLM

Mô hình ngôn ngữ lớn (LLM) là mô hình học sâu được huấn luyện trên lượng lớn dữ liệu văn bản nhằm hiểu và sinh ngôn ngữ tự nhiên. Trong hệ thống RAG, LLM không trực tiếp tìm kiếm dữ liệu mà chịu trách nhiệm phân tích ngữ cảnh được truy xuất, hiểu yêu cầu prompt đã tạo, suy luận, tổng hợp và tạo ra câu trả lời tự nhiên cho người dùng

So sánh vai trò của LLM đơn thuần và kết hợp với RAG

LLM đơn thuần	LLM với RAG
Trả lời dựa trên dữ liệu đã huấn luyện	Trả lời dựa trên dữ liệu được truy xuất
Dễ bị hiện tượng “Ảo giác”	Giảm bị hiện tượng “Ảo giác”
Không biết dữ liệu nội bộ	Hiểu dữ liệu nội bộ


→ RAG không thay đổi mô hình LLM mà tăng cường khả năng trả lời bằng cách cung cấp ngữ cảnh liên quan trước khi sinh phản hồi

So sánh các mô hình ngôn ngữ lớn (LLM)

Model	Ưu điểm	Hạn chế
GPT-5 / GPT-5 mini	Khả năng suy luận mạnh, tuân thủ prompt, tốc độ và chất lượng trả lời tốt	Có chi phí sử dụng
Gemini 2.5	Đa phương thức (văn bản, hình ảnh), tốc độ tốt	API thay đổi theo dịch vụ
Claude 4	Đọc tài liệu dài, lập luận tốt	Chi phí, giới hạn khu vực và tốc độ chậm hơn
Llama 3.3	Có thể triển khai cục bộ, tùy chỉnh cao	Cần GPU mạnh để chạy hiệu quả

→ Trong dự án, chọn GPT-5 mini bởi các ưu điểm về chất lượng và thời gian phản hồi, ngoài ra đồng bộ với bộ Embedding Model đã được sử dụng của OpenAI


Ý nghĩa của chức năng đề xuất



PHẦN 3: ĐÁNH GIÁ GIẢI PHÁP

Kiểm nghiệm thực tế và so sánh hiệu quả

Input và Output của giải pháp đề xuất




So sánh với một số giải pháp hiện có

Giải pháp	Ưu điểm	Nhược điểm
Tìm kiếm truyền thống (Keyword Search)	Nhanh và dễ triển khai cho chủ doanh nghiệp	Phụ thuộc từ ngữ tìm kiếm và lượng dữ liệu được chuẩn bị sẵn. Người dùng phải đọc lượng lớn dữ liệu để tìm thông tin
Chatbot dựa trên kịch bản cố định (Rule-based Chatbot)	Dễ triển khai với công nghệ hơn và vượt trội hơn kiểu tìm kiếm truyền thống	Chatbot không hiểu về mặt ngữ nghĩa, chỉ hiểu được hội thoại đơn giản, kém hiệu quả với câu hỏi diễn đạt phức tạp, khiến giảm sự hài lòng của khách hàng
Chatbot dựa vào mô hình ngôn ngữ lớn thuần (LLM)	Câu trả lời có độ tự nhiên cao với lượng dữ liệu tổng hợp lớn	Dễ bị ảo giác hay mất ngữ cảnh khi giao tiếp, nguy cơ về bảo mật dữ liệu nội bộ
Chatbot dựa vào hệ thống truy xuất (RAG)	Hệ thống hiểu ngữ cảnh tốt hơn. Có thể cập nhật lại dữ liệu nội bộ nhanh chóng dựa trên mô hình ngôn ngữ lớn có sẵn.	Cần thời gian, công sức xây dựng bộ kiến thức nền, các câu hỏi phổ biến để giúp hệ thống truy xuất

Phương thức đo đạc chất lượng (Các tiêu chí)

Nhóm	Tiêu chí	Miêu tả	Ví dụ
Retrieval	Precision@k	Trong k tài liệu trả về có bao nhiêu tài liệu đúng	- Top 5 (1:S, 2:D, 3:S, 4:D, 5:S) → Precision@k = 2/5=0.4 (40%)
	Recall@k	Bao nhiêu tài liệu đúng đã tìm thấy trong Top k	- Tổng cộng 4 document đúng. - Top k=5 tìm được 3 document đúng → Recall@5 = 3/4 = 0.75 (75%)
	MRR (Mean Reciprocal Rank)	Tài liệu đúng đầu tiên đứng ở vị trí bao nhiêu	- Rank 1: D, Rank 2: S, Rank 3: D → MRR = 1/1 = 100% - Rank 1: S, Rank 2: D, Rank 3: D → MRR = 1/2 = 50% - Rank 1: S, Rank 2: S, Rank 3: D → MRR = 1/3 ~ 33%
Generation	Faithfulness	Kiểm tra câu trả lời dựa ngữ cảnh hay không (dùng công cụ RAGAS đánh giá)	Context: Recursive chunking chia tài liệu theo heading LLM Generation 1: Recursive chunking chia theo heading → Faithfulness 1 = Cao LLM Generation 2: Recursive chunking được phát triển năm 2023 → Faithfulness 2 = Thấp (Context không có)
	Aswer Relevancy	Kiểm tra câu trả lời đúng câu hỏi không (dùng công cụ RAGAS đánh giá)	Question: Embedding là gì? Aswer 1: Embedding chuyển văn bản thành vector → Rất liên quan Aswer 2: Embedding được OpenAI phát triển → Không liên quan
	Context Precision	Kiểm tra ngữ cảnh đưa vào Prompt có thực sự cần thiết không (dùng công cụ RAGAS đánh giá)	Prompt: Chứa 10 chunk LLM: 2 chunk hữu ích → Độ chính xác ngữ cảnh thấp
	Context Recall	Kiểm tra có thiếu ngữ cảnh quan trọng không (dùng công cụ RAGAS đánh giá)	Groud Truth: Chunk A, B, C Retriever: Chunk A, B → Thiếu C, Recall thấp
Performance	Response Time	Đánh giá tốc độ phản hồi hệ thống	Đo thời gian từ lúc bắt đầu truy xuất đến khi LLM trả lời đáp

Bảng liệt kê các tiêu chí



Đánh giá qua RAGAS

Thiết kế thí nghiệm

Bước 1: Thu thập 50-100 câu hỏi thực tế của khách hàng từ các Fanpage của các thương hiệu nến nổi tiếng

Bước 2: Tự biên soạn câu trả lời mẫu chuẩn (Ground Truth) chuẩn và các đoạn chunk (nguồn cụ thể) để làm thước đo chấm điểm các câu hỏi kiểm thử

Bước 3: Chạy thử nghiệm hệ thống RAG, dùng mô hình LLM nhẹ hơn để chấm điểm với thông tin đưa sẵn và công cụ RAGAS (LLM Based) để chấm các tiêu chí

Bước 4: Điều chỉnh các thông số RAG dựa trên kết quả thực nghiệm

Quy trình biên soạn câu hỏi và chạy kiểm thử

```
Test_Candle_knowledge_Vietnamese.json X
FastAPI_AI_Service > app > data > NenThom_data > Candles_Knowledge > Tests > Test_Candle_knowledge_Vietnamese.json > {} 3 > abc ground_tr

1  [
2
3    {
4      "question": "Các nốt hương đầu (top notes) thường kéo dài bao lâu sau khi đốt nến?",
5      "ground_truth_answer": "Các nốt hương đầu thường kéo dài khoảng 10 phút sau khi nến được thắp sáng.",
6      "relevant_docs": [
7        "Some_Fragrance_layers_of_scented_candles.docx"
8      ]
9    },
10   {
11     "question": "Tại sao nốt hương giữa (middle notes) được xem là linh hồn của cây nến?",
12     "ground_truth_answer": "Nốt hương giữa được xem là linh hồn của cây nến vì chúng tồn tại lâu nhất và d
13     "relevant_docs": [
14       "Some_Fragrance_layers_of_scented_candles.docx"
15     ]
16   },
17   {
18     "question": "Hãy kể tên hai nốt hương gỗ nền (base notes) phổ biến được tìm thấy trong nến thơm.",
19     "ground_truth_answer": "Gỗ đàn hương (sandalwood) và gỗ tuyết tùng (cedarwood).",
20     "relevant_docs": [
21       "Some_Fragrance_layers_of_scented_candles.docx"
22     ]
23   }
24 ],
```

```
Test_Candle_knowledge.json X
FastAPI_AI_Service > app > data > NenThom_data > Candles_Knowledge > Tests > Test_Candle_knowledge.json > ...

1  [
2
3    {
4      "question": "How long do top notes typically last after a candle is lit?",
5      "ground_truth_answer": "Top notes usually last about 10 minutes after the candle is lit.",
6      "relevant_docs": [
7        "Some_Fragrance_layers_of_scented_candles.docx"
8      ]
9    },
10   {
11     "question": "Why are middle notes considered the soul of a candle?",
12     "ground_truth_answer": "Middle notes are considered the soul of a candle because they are the
13     "relevant_docs": [
14       "Some_Fragrance_layers_of_scented_candles.docx"
15     ]
16   },
17   {
18     "question": "Name two common woody base notes found in scented candles.",
19     "ground_truth_answer": "Sandalwood and cedarwood.",
20     "relevant_docs": [
21       "Some_Fragrance_layers_of_scented_candles.docx"
22     ]
23   }
24 ],
```

Câu hỏi tiếng Việt và tiếng Anh cho kiểm thử

So sánh kết quả thực thi

Kiểm tra loại câu hỏi về Kiến thức nền thơm (Candle Knowledge)

Nhóm tiêu chí	Tiêu chí đánh giá	Bộ tìm kiếm	Bộ Ngôn ngữ gốc		Bộ dịch sang Tiếng Anh	
		Ngôn ngữ dữ liệu kiểm thử	Tiếng Việt	Tiếng Anh	Tiếng Việt	Tiếng Anh
Sự truy xuất	Độ chính xác		63 %	83 %	90 %	80 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 5)		70 %	100 %	90 %	100 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 3)		60 %	100 %	60 %	100 %
	Thứ hạng tương hỗ (MRR)		62 %	90 %	58 %	90 %
Sự sinh câu trả lời	Sự trung thực		63 %	82.4 %	88 %	80 %
	Sự liên quan câu trả lời		60 %	78 %	84 %	77 %
	Độ chính xác ngữ cảnh		60 %	88 %	86 %	87 %
	Độ truy xuất đúng ngữ cảnh		57 %	95 %	93 %	95 %
Thời gian	Thời gian trung bình		12.1 s	7.3 s	10.2 s	7 s
	Thời gian của 95% mẫu thử		22.5 s	13 s	17.4 s	10.7 s

- Hiệu quả về độ chính xác và thời gian khi sử dụng với bộ dịch Tiếng Anh cho cả câu hỏi tiếng anh hay tiếng việt

So sánh kết quả thực thi (tt 1)

Kiểm tra loại câu hỏi về **Chương trình khuyến mãi (Discount program)**

Nhóm tiêu chí	Tiêu chí đánh giá	Bộ tìm kiếm	Bộ Ngôn ngữ gốc		Bộ dịch sang Tiếng Anh	
		Ngôn ngữ dữ liệu kiểm thử	Tiếng Việt	Tiếng Anh	Tiếng Việt	Tiếng Anh
Sự truy xuất	Độ chính xác		100 %	80 %	85 %	85 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 5)		100 %	100 %	100 %	100 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 3)		100 %	100 %	100 %	100 %
	Thứ hạng tương hỗ (MRR)		100 %	97 %	97 %	97 %
Sự sinh câu trả lời	Sự trung thực		88 %	81 %	87 %	83 %
	Sự liên quan câu trả lời		91 %	84 %	83 %	83 %
	Độ chính xác ngữ cảnh		80 %	79 %	76 %	79 %
	Độ truy xuất đúng ngữ cảnh		100 %	91 %	83 %	88 %
Thời gian	Thời gian trung bình		7.7 s	6.9 s	8.1 s	7 s
	Thời gian của 95% mẫu thử		12.8 s	10.4 s	14.6 s	10.9 s

- Hiệu quả về độ chính xác và thời gian khi sử dụng với **bộ dịch Tiếng Anh** cho cả câu hỏi tiếng anh hay tiếng việt

So sánh kết quả thực thi (tt 2)

Kiểm tra loại câu hỏi về **Các chính sách (Policies)**

Nhóm tiêu chí	Tiêu chí đánh giá	Bộ tìm kiếm	Bộ Ngôn ngữ gốc		Bộ dịch sang Tiếng Anh	
		Ngôn ngữ dữ liệu kiểm thử	Tiếng Việt	Tiếng Anh	Tiếng Việt	Tiếng Anh
Sự truy xuất	Độ chính xác		93 %	90 %	90 %	93 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 5)		100 %	100 %	100 %	100 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 3)		100 %	100 %	100 %	100 %
	Thứ hạng tương hỗ (MRR)		100 %	93 %	93 %	93 %
Sự sinh câu trả lời	Sự trung thực		88 %	86 %	91 %	85 %
	Sự liên quan câu trả lời		92 %	94 %	90 %	90 %
	Độ chính xác ngữ cảnh		80 %	88 %	84 %	87 %
	Độ truy xuất đúng ngữ cảnh		100 %	100 %	97 %	100 %
Thời gian	Thời gian trung bình		7.3 s	4.89 s	7.7 s	6.6 s
	Thời gian của 95% mẫu thử		11.9 s	6.65 s	11.7 s	9.9 s

- Hiệu quả về độ chính xác và thời gian khi sử dụng với **bộ dịch Tiếng Anh** cho cả câu hỏi tiếng anh hay tiếng việt

So sánh kết quả thực thi (tt 3)

Kiểm tra loại câu hỏi về **Danh sách sản phẩm (Product catalog)**

Nhóm tiêu chí	Tiêu chí đánh giá	Bộ tìm kiếm	Bộ Ngôn ngữ gốc		Bộ dịch sang Tiếng Anh	
		Ngôn ngữ dữ liệu kiểm thử	Tiếng Việt	Tiếng Anh	Tiếng Việt	Tiếng Anh
Sự truy xuất	Độ chính xác		100 %	95 %	95 %	95 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 5)		100 %	100 %	95 %	100 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 3)		100 %	90 %	90 %	90 %
	Thứ hạng tương hỗ (MRR)		98 %	92 %	91 %	92 %
Sự sinh câu trả lời	Sự trung thực		98 %	96 %	93 %	96 %
	Sự liên quan câu trả lời		92 %	92 %	86 %	92 %
	Độ chính xác ngữ cảnh		95 %	86 %	83 %	83 %
	Độ truy xuất đúng ngữ cảnh		100 %	100 %	95 %	100 %
Thời gian	Thời gian trung bình		6.1 s	4 s	6.2 s	4.6 s
	Thời gian của 95% mẫu thử		10.9 s	5 s	9.5 s	6.6 s

Khả năng tìm kiếm bằng tiếng việt đạt kết quả vượt trội tùy thuộc vào cấu trúc tập dữ liệu cơ sở

- Trong tập dữ liệu của Danh sách sản phẩm, có các từ khóa (Keyword) tiếng việt, giúp cải thiện khả năng tìm kiếm bằng tiếng Việt

Amber_And_Vanilla.md X

```
FastAPI_AI_Service > app > data > NenThom_data > Product_Catalogs > Amber
62 - Bedroom fragrance
63 - Fall and winter décor
64 - Gift giving
65 - Reading sessions
66 - Movie nights
67 - Warm home ambience
68
69 Keywords: Western Brook Candle, Amber Vanilla Candle, H
Scented Candle, Gourmand Candle, Sweet Candle, Glass Ja
70
71 Vietnamese Keywords: nến thơm amber vanilla, nến western
khách, nến mùa thu, nến mùa đông, nến hương ấm áp, nến
72
```

- Tìm kiếm bằng **bộ ngôn ngữ gốc** giúp **cải thiện truy xuất và độ chính xác**
- Tìm kiếm bằng **bộ dịch Tiếng Anh** giúp **cải thiện thời gian**

So sánh kết quả thực thi (tt 4)

Kiểm tra loại câu hỏi về **Hướng dẫn sử dụng (User Guidance)**

Nhóm tiêu chí	Tiêu chí đánh giá	Bộ tìm kiếm	Bộ Ngôn ngữ gốc		Bộ dịch sang Tiếng Anh	
		Ngôn ngữ dữ liệu kiểm thử	Tiếng Việt	Tiếng Anh	Tiếng Việt	Tiếng Anh
Sự truy xuất	Độ chính xác		90 %	90 %	90 %	90 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 5)		80 %	100 %	90 %	100 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 3)		80 %	100 %	90 %	100 %
	Thứ hạng tương hỗ (MRR)		53 %	80 %	85 %	80 %
Sự sinh câu trả lời	Sự trung thực		83 %	91 %	88 %	92 %
	Sự liên quan câu trả lời		80 %	92 %	92 %	93 %
	Độ chính xác ngữ cảnh		73 %	90 %	92 %	91 %
	Độ truy xuất đúng ngữ cảnh		90 %	100 %	100 %	100 %
Thời gian	Thời gian trung bình		6.7 s	5.3 s	6.3 s	5.6 s
	Thời gian của 95% mẫu thử		9.7 s	7 s	8.8 s	7.1 s

- Hiệu quả về độ chính xác và thời gian khi sử dụng với **bộ dịch Tiếng Anh** cho cả câu hỏi tiếng anh hay tiếng việt

So sánh kết quả thực thi (tt 5)

Tổng hợp các kết quả kiểm tra

Nhóm tiêu chí	Tiêu chí đánh giá	Bộ tìm kiếm	Bộ Ngôn ngữ gốc		Bộ dịch sang Tiếng Anh	
		Ngôn ngữ dữ liệu kiểm thử	Tiếng Việt	Tiếng Anh	Tiếng Việt	Tiếng Anh
Sự truy xuất	Độ chính xác		86.4 %	87.5 %	90 %	88.3 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 5)		88.2 %	100 %	95 %	100 %
	Độ truy xuất đúng dữ liệu (Dữ liệu liên quan trong Top 3)		85.5 %	98.3 %	86.7 %	98.3 %
	Thứ hạng tương hỗ (MRR)		80.7 %	90.6 %	83.1 %	90.6 %
Sự sinh câu trả lời	Sự trung thực		82 %	86.1 %	89.4 %	86.4 %
	Sự liên quan câu trả lời		80.9 %	87.5 %	87 %	86.2 %
	Độ chính xác ngữ cảnh		76.2 %	86.3 %	84.3 %	85.7 %
	Độ truy xuất đúng ngữ cảnh		86.4 %	97.2 %	93.7 %	96.7 %
Thời gian	Thời gian trung bình		8.3 s	6.2 s	7.9 s	6.3 s
	Thời gian của 95% mẫu thử		14.3 s	9.4 s	12.8 s	9.3 s

- Tìm kiếm bằng **bộ ngôn ngữ gốc** giúp cải thiện khả năng truy xuất nếu ngôn ngữ hỏi giống ngôn ngữ làm tài liệu
 - Tìm kiếm bằng **bộ dịch Tiếng Anh** giúp cải thiện thời gian và độ chính xác cao hơn
- Nên dùng **bộ dịch Tiếng Anh** đem lại nhiều lợi ích hơn và cân bằng về hiệu suất theo nhiều mặt

Kết quả demo dự án

Link Youtube: <https://www.youtube.com/watch?v=kW8ot0YEB9c>


Q&A

Cảm ơn Hội đồng đã lắng nghe!


Email liên hệ: nguyentrungtin1002@gmail.com

Kiến trúc tổng quát hệ thống

1. Document Processing Routine



2. Advance Answering Routine (with detect purpose question)



Sơ đồ kiến trúc ứng dụng AI với RAG và LLM
(cải tiến phân loại câu hỏi)